

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.8

Отчет об исследовательском проекте на тему:
Тестирование методов оптимизации МОП
(промежуточный, этап 1)

Выполнил студент:

группы #БПМИ249, 2 курса Заренков Пётр Иванович

Принял руководитель проекта:

Новиков Иван Сергеевич
Кандидат физико-математических наук
Доцент
Факультет компьютерных наук НИУ ВШЭ

Москва 2026

Содержание

Аннотация	3
Ключевые слова	3
1 Уже сделанная работа	3
2 Индивидуальный проект: тестирование методов оптимизации машинно-обучаемых потенциалов	6
2.1 Цель и постановка задачи	6
2.2 Обзор литературы	7
2.3 План выполнения индивидуального проекта	7
2.4 Ожидаемые результаты и критерии сравнения	9
Список литературы	10

Аннотация

В отчёте представлен план индивидуальной части курсового проекта, посвящённой тестированию методов оптимизации при обучении машинно-обучаемых межатомных потенциалов в задаче регрессии энергий и сил атомных конфигураций. Определены целевые семейства моделей (MTP, ETN, DeepMD), используемые наборы данных и единый протокол сравнения. Рассматриваемые методы оптимизации структурированы по классу используемой информации и режиму вычисления градиента: методы первого порядка при оптимизации по полному датасету и в стохастической постановке с мини-пакетами, а также квазиньютоновские методы второго порядка (BFGS и варианты с ограниченной памятью). Сформулированы этапы реализации вычисления значения функции потерь и её градиента для интеграции внешних оптимизаторов, а также критерии сопоставления методов по ошибкам на обучающей и валидационной выборках, устойчивости процесса обучения и вариативности результатов по ансамблю моделей.

Ключевые слова

машинно-обучаемые межатомные потенциалы; регрессия энергий и сил; обучение по энергиям и силам; функция потерь; градиент; оптимизация; градиентный спуск; стохастический градиентный спуск; Adam; квазиньютоновские методы; BFGS; L-BFGS; Moment tensor potential; тензорные сети; эквивариантность; Equivariant tensor network potentials; DeepMD; ансамбли моделей; валидационная ошибка

1 Уже проделанная работа

Данный раздел носит обзорный характер и фиксирует результаты, полученные до начала индивидуальной части.

1. Вводное занятие по установке программного окружения и работе на вычислительном кластере (12.11.25): освоены базовые элементы вычислительного окружения и запуск расчётов на кластере, включая работу с планировщиком задач и параллельными вычислениями.
2. Основные понятия задачи регрессии и линейная регрессия (19.11.25): изучены постановка задачи регрессии, функционал ошибки и базовые подходы к оценке качества

модели на данных. На практике была исследована ошибка RMSE по энергии и силам от числа параметров МТР, построены паретто-фронты.




Рис. 1.1

3. Нелинейная регрессия на примере полиномиального потенциала (03.12.25): рассмотрены принципы нелинейной аппроксимации и влияние сложности модели на качество приближения. Главным выводом стало сравнение изменения ошибки RMSE для потенциалов DeepMD и МТР.




Рис. 1.2

4. Нелинейная регрессия на примере нейросетевого потенциала (10.12.25): изучены общие идеи параметрических нелинейных моделей и особенности их обучения в контексте аппроксимации потенциальной энергии.
5. Кривые обучения и переобучение. Кросс-валидация. Виды целевых функций в задаче регрессии (24.12.25): изучены критерии качества, разбиение на обучающую и валидационную выборки, а также принципы интерпретации кривых обучения.
6. Универсальные машинно-обучаемые потенциалы (14.01.26): выполнены первичные эксперименты по обучению потенциалов МТР на данных с энергиями и силами из DFT

и проведена оценка ошибок на обучающей и валидационной выборках. На практике получено сравнение ошибки RMSE между МТР, предобученного на MatterSim данных и дообученного на DFT данных и МТР, обученного сразу на DFT данных.




Рис. 1.3

7. Активное обучение машинно-обучаемых потенциалов (21.01.26): подготовлены скрипты для пакетного запуска серий экспериментов и сохранения метрик обучения и валидации в табличном виде.
8. Малоранговые машинно-обучаемые потенциалы (28.01.26): изучены материалы по низкоранговым приближениям и сжатию параметризаций машинно-обучаемых потенциалов, включая усечённое SVD, скелетное разложение, tensor train и их применение для уменьшения числа параметров МТР и построения эквивариантного тензорно-сетевого потенциала ETN.

2 Индивидуальный проект: тестирование методов оптимизации машинно-обучаемых потенциалов

2.1 Цель и постановка задачи

Целью индивидуальной части является систематическое сравнение методов оптимизации при обучении машинно-обучаемых межатомных потенциалов в задаче регрессии энергий и сил атомных конфигураций. Планируется исследовать влияние оптимизаторов на:

1. скорость сходимости алгоритма оптимизации при минимизации функции потерь по параметрам потенциала;
2. качество аппроксимации энергий и сил, измеряемое ошибками на обучающей и валидационной выборках;
3. вариативность результатов по ансамблю моделей, то есть разброс качества между независимыми запусками одной и той же модели при различных инициализациях параметров.

Объектами исследования выступают три семейства потенциалов:

1. **Moment Tensor Potentials (MTP)** как аналитически параметризованный класс машинно-обучаемых межатомных потенциалов, обеспечивающий систематическое усложнение модели и широко применяемый в задачах атомистического моделирования.
2. **Equivariant Tensor Network (ETN)** как представитель тензорно-сетевых подходов с эквивариантной структурой, ориентированных на построение потенциалов с учётом симметрий.
3. **Deep Potential Molecular Dynamics (DeepMD)** как нейросетевой класс межатомных потенциалов, использующий глубокие модели для аппроксимации поверхности потенциальной энергии и соответствующих сил, и выступающий как масштабируемая альтернатива для сопоставления с MTP и ETN в едином экспериментальном протоколе.

Сравниваемые оптимизационные методы включают:

1. градиентный спуск;
2. стохастический градиентный спуск (и его типовые модификации на уровне мини-пакетов);

3. Adam;
4. BFGS и близкие к нему квазиньютоновские методы (включая варианты с ограниченной памятью, где применимо).

2.2 Обзор литературы

Для обучения МТР ключевыми являются постановка функции потерь по энергиям и силам и численная оптимизация параметров модели. Описание moment tensor potentials и практических аспектов их обучения, включая реализацию в пакете MLIP, приведено в работах [5, 7].

Квазиньютоновские методы (в частности BFGS и L-BFGS) являются стандартным инструментом гладкой оптимизации в задачах регрессии и идентификации параметров; их свойства, условия применимости и практические рекомендации систематически изложены в классических источниках по численной оптимизации [4, 9].

Методы градиентного и стохастического градиентного спуска применяются в задачах обучения параметризованных моделей большой размерности и остаются базовыми подходами для оптимизации в машинном обучении; обзор современных постановок и практических аспектов (включая проблемы масштаба, шума градиента и критерии останова) представлен в работе по методам оптимизации для крупномасштабного машинного обучения [1].

Алгоритм Adam является широко используемым адаптивным методом первого порядка, особенно в задачах, где требуется баланс между скоростью сходимости и устойчивостью при шумных оценках градиента; оригинальная постановка алгоритма и его ключевые эвристики приведены в исходной публикации [3].

Для тензорно-сетевых моделей и их обучения важны вопросы оптимизации параметров с учётом структурных ограничений и симметрий. В качестве базовой теоретической опоры используются обзоры по тензорным сетям и их оптимизации в задачах обучения, а также работы по обучению тензорно-сетевых моделей в задачах supervised learning [6, 8]. Для эквивариантных тензорных сетей в задачах межатомных потенциалов используются постановки, ориентированные на аппроксимацию потенциальной энергии и сил с учётом симметрий системы [2].

2.3 План выполнения индивидуального проекта

В рамках промежуточного отчёта фиксируется план предстоящих работ и ожидаемые результаты каждого этапа.

1. **Обучение ансамбля ETN методом BFGS на базе данных AgPd.** Предполагается обучить ансамбль моделей ETN на фиксированном наборе конфигураций AgPd, используя квазиньютоновскую оптимизацию. Основная метрика этапа — разброс ошибки на валидационной выборке между разными инициализациями и сравнение полученного распределения ошибок с распределением для MTP при сопоставимых настройках.
2. **Систематизация оптимизационных методов для задачи регрессии параметров потенциалов.** Планируется выделить единый формализм функции потерь и градиента для рассматриваемых потенциалов, а также описать применимость методов первого порядка (градиентный/стохастический градиентный спуск, Adam) и методов второго порядка/квазиньютоновских (BFGS/L-BFGS). Дополнительно планируется уточнить набор реализованных оптимизаторов в `scipy.optimize` и зафиксировать, какие методы требуется реализовать вручную (например, Adam и SGD в типичной постановке мини-пакетов).
3. **Реализация проброса значения функции потерь и её градиента для обучения MTP во внешние оптимизаторы.** Требуется построить интерфейс, который по параметрам потенциала возвращает значение функции потерь и градиент по параметрам. Далее планируется выполнить обучение MTP с использованием BFGS из `scipy.optimize` и сравнить результат с обучением стандартными средствами пакета, применяемыми в базовых экспериментах.
4. **Сравнение оптимизаторов при обучении MTP и ETN на наборах AgPd и MoNbTaW.** Планируется провести серию запусков для разных оптимизаторов, зафиксировать ошибки на обучении и валидации, а также долю «успешных» запусков в ансамбле. Успешность предлагается определять по достижению целевого уровня валидационной ошибки и отсутствию деградации метрик на обучении при фиксированном лимите итераций.
5. **Возмущение параметров при обучении ETN и анализ устойчивости.** Для повышения устойчивости ансамблевого обучения предполагается добавить контролируемые возмущения параметров в процессе оптимизации и проверить, уменьшается ли разброс качества по ансамблю. Метрики сравнения соответствуют этапу 4: валидационная ошибка и доля успешных запусков.
6. **Дополнительный этап: перенос протокола на DeePMD.** При наличии времени планируется применить аналогичный протокол сравнения оптимизаторов к DeePMD и

сопоставить результаты с МТР и ETN по тем же метрикам.

2.4 Ожидаемые результаты и критерии сравнения

Ожидается получить:

1. воспроизводимый экспериментальный протокол сравнения оптимизаторов для МТР и ETN;
2. оценки влияния выбора оптимизатора на качество валидации и устойчивость ансамблей;
3. практические рекомендации по выбору оптимизации в зависимости от модели (МТР/ETN), размера данных и требований к стабильности;
4. результаты тестирования выбранных методов оптимизации на модели DeerpMD и сопоставление их поведения с МТР и ETN.

В качестве критериев сравнения используются ошибки на обучающей и валидационной выборках, статистики разброса по ансамблю (например, медиана и межквартильный размах), а также доля запусков, удовлетворяющих заданному порогу качества. Для экспериментов с DeerpMD дополнительно фиксируются особенности вычислительных затрат (время обучения, использование ресурсов) и стабильность сходимости при одинаковых протоколах подбора гиперпараметров.

Список литературы

- [1] Léon Bottou, Frank E. Curtis и Jorge Nocedal. “Optimization Methods for Large-Scale Machine Learning”. В: *SIAM Review* 60.2 (2018), с. 223—311. DOI: [10.1137/16M1080173](https://doi.org/10.1137/16M1080173).
- [2] Markus Hodapp и Alexander Shapeev. “Equivariant tensor networks for interatomic potentials”. В: (2025). arXiv:2504.15760.
- [3] Diederik P. Kingma и Jimmy Ba. “Adam: A Method for Stochastic Optimization”. В: *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. arXiv:1412.6980. 2015.
- [4] Jorge Nocedal и Stephen J. Wright. *Numerical Optimization*. 2-е изд. Springer, 2006. DOI: [10.1007/978-0-387-40065-5](https://doi.org/10.1007/978-0-387-40065-5).
- [5] Ivan S. Novikov, Konstantin Gubaev, Evgeny V. Podryabinkin и Alexander V. Shapeev. “The MLIP package: moment tensor potentials with MPI and active learning”. В: *Machine Learning: Science and Technology* 2.2 (2021), с. 025002. DOI: [10.1088/2632-2153/abc9fe](https://doi.org/10.1088/2632-2153/abc9fe).
- [6] Román Orús. “A practical introduction to tensor networks: Matrix product states and projected entangled pair states”. В: *Annals of Physics* 349 (2014), с. 117—158. DOI: [10.1016/j.aop.2014.06.013](https://doi.org/10.1016/j.aop.2014.06.013).
- [7] Alexander V. Shapeev. “Moment tensor potentials: A class of systematically improvable interatomic potentials”. В: *Multiscale Modeling & Simulation* 14.3 (2016), с. 1153—1173. DOI: [10.1137/15M1054183](https://doi.org/10.1137/15M1054183).
- [8] Edwin M. Stoudenmire и David J. Schwab. “Supervised Learning with Quantum-Inspired Tensor Networks”. В: (2016). arXiv:1605.05775.
- [9] Stephen J. Wright. *Primal-Dual Interior-Point Methods*. SIAM, 1997. DOI: [10.1137/1.9781611971452](https://doi.org/10.1137/1.9781611971452).