




Сравнение универсальных машинно-обучаемых межатомных потенциалов с МТР-потенциалами, обученными с нуля

Тонкая настройка MatterSim и MACE против обучения МТР-16 / МТР-20



Булат Маннанов

Научно-учебная группа «Машинное обучение в атомистическом моделировании»

13 мая 2026



Постановка работы: что сравниваем

Сравниваем два подхода к построению потенциала для целевой системы: fine-tuning универсальной модели и обучение MTP с нуля.

Универсальные модели

- MatterSim
- MACE
- предварительное обучение
- fine-tuning на целевых данных

единая
проверка

MTP: базовый вариант

- MTP-16
- MTP-20
- обучение с нуля
- нет message passing

Проверяем на organic* / H₂O / MoNbTaVW; метрики: Energy MAE/RMSE (meV/atom), Forces MAE/RMSE (meV/Å).

*organic обозначает 3BPA (молекулярный датасет); 300/600/1200 K — температуры MD.

Дальше: какие архитектурные идеи позволяют MatterSim и MACE представлять атомную структуру и получать энергию/силы.



Что должен выучить ML-потенциал?

Модель аппроксимирует поверхность потенциальной энергии; силы получаются как её производные.



Физические требования к архитектуре

перенос / поворот

$$E(Z, QR + t) = E(Z, R)$$

одинаковые атомы

$$E(PZ, PR) = E(Z, R)$$

согласованные силы


$$F_i = -\partial E_\theta / \partial r_i$$

при повороте: $F \rightarrow QF$



M3GNet: от атомной структуры к энергии

M3GNet представляет атомную структуру как граф, обновляет признаки атомов и связей с учётом расстояний и углов, а затем предсказывает полную энергию как сумму атомных вкладов.




Многочастный блок добавляет информацию о тройках атомов и углах; силы получаются как производные полной энергии.

Схема построена по Chen & Ong, M3GNet, Fig. 1.



Graph featurizer: построение признаков графа

Graph featurizer переводит химический тип атома и геометрию соседства в численные признаки графа.




После фичеризации граф уже содержит признаки атомов, связей и состояния; дальше они поступают в многочастный блок и графовую свёртку.

Схема построена по Chen & Ong, M3GNet, Fig. 1.



Three-body block: тройки атомов и углы

M3GNet дополняет парные расстояния угловой информацией о тройках атомов.




Углы позволяют модели учитывать локальную геометрию окружения, а не только расстояния между парами атомов.

Схема построена по Chen & Ong, M3GNet, Fig. 1.



Many-body-to-bond: как углы обновляют связи

Для связи $i-j$ M3GNet суммирует вклады соседей k и получает контекстный признак связи.



Признак связи e_{ij} становится контекстным: он зависит от локального окружения атома i .


$$\Delta e_{ij} = \sum_{k \in \mathcal{N}_i \setminus \{j\}} \phi(r_{ij}, r_{ik}, \theta_{jik}, v_k), \quad \tilde{e}_{ij} = e_{ij} + \Delta e_{ij}.$$

Схема построена по Chen & Ong, M3GNet, Fig. 1.



Graph convolution: обновление признаков графа

После many-body-to-bond M3GNet итеративно обновляет связи, атомы и состояние.




После нескольких графовых блоков атомные признаки готовы для считывания атомных энергий.

Схема построена по Chen & Ong, M3GNet, Fig. 1.



Readout: энергия, силы и напряжения

Сначала M3GNet считывает энергию, а силы и напряжения получает как производные полной энергии.




Одна энергетическая поверхность задаёт и энергии, и силы; поэтому предсказания физически согласованы.

Схема построена по Chen & Ong, M3GNet, Fig. 1.



MatterSim: предобучение и тонкая настройка

Предобученная модель уже содержит общее физико-химическое представление; тонкая настройка уточняет его под конкретный датасет.




По Yang et al., MatterSim, Fig. 1–2.



MatterSim в нашем эксперименте

Берём предобученный MatterSim, тонко настраиваем на целевых датасетах и оцениваем энергии и силы на отложенных выборках.






MACE: зачем нужна эквивариантность?

Геометрия атомной системы должна сохраняться в энергии и корректно переноситься в силы.

Энергия: инвариантность

invariance




$$E(QR) = E(R)$$

поворот не меняет скалярную энергию

Силы: эквивариантность

equivariance



$$\mathbf{F}(QR) = Q\mathbf{F}(R)$$

векторы сил поворачиваются
вместе со структурой


MACE строит внутренние признаки так, чтобы они преобразовывались согласованно с поворотами.

MACE использует геометрически эквивариантные признаки.



MACE: локальное окружение, расстояния и направления

MACE строит сообщения по локальному окружению атома: расстояние задаёт близость соседа, направление задаёт ориентацию в пространстве.




Следующий шаг: расстояние кодируется радиальными функциями, а направление – сферическими гармониками.

Схема построена по Batatia et al., MACE.



MACE: кодирование геометрии ребра

Расстояние задаёт радиальную часть, направление — угловую часть признака ребра.



Следующий шаг: эти признаки смешиваются с атомными признаками через тензорное произведение.

Схема построена по Batatia et al., MACE.



Spherical harmonics: как поворачиваются угловые каналы

Радиальная часть инвариантна, а компоненты углового канала смешиваются по правилу поворота.




Схема построена по Batatia et al., MACE.



MACE: эквивариантные признаки

Признаки делятся на l -каналы, которые преобразуются по-разному при поворотах.



Так MACE передаёт геометрию локального окружения без нарушения правил поворота.

Схема построена по Batatia et al., MACE.



MACE: два interaction blocks

Стандартный MACE pipeline: два повторения message construction/update; число блоков остаётся гиперпараметром.

Формулы MACE architecture

Block 1

$$A_i^{(1)} \rightarrow B_i^{(1)} \rightarrow m_i^{(1)} \rightarrow h_i^{(1)}$$

Block 2

$$A_i^{(2)} \rightarrow B_i^{(2)} \rightarrow m_i^{(2)} \rightarrow h_i^{(2)}$$

input
edge

$$Z_i \rightarrow h_i^{(0)}, \quad \mathbf{r}_{ji} = \mathbf{r}_j - \mathbf{r}_i, \quad \hat{\mathbf{r}}_{ji} = \mathbf{r}_{ji} / \|\mathbf{r}_{ji}\|,$$

$$\phi_{ji}^{nlm} = R_n(r_{ji}) Y_l^m(\hat{\mathbf{r}}_{ji})$$

A

$$A_{i,klm}^{(1)} = \sum_{j \in N(i)} R_{kl}^{(1)}(r_{ji}) Y_l^m(\hat{\mathbf{r}}_{ji}) W_{kzj}^{(1)}$$

$$A_i^{(t)} = \text{Pool}_{j \in N(i)} (R^{(t)} Y h_j^{(t)})$$

B

$$B_{i,\eta\nu,kLM}^{(t)} = \sum_{l,m} C_{\eta\nu,lm}^{LM} \prod_{\xi=1}^{\nu} \sum_{\bar{k}} w_{\bar{k}kl\xi}^{(t)} A_{i,\bar{k}l\xi}^{(t)} m_{\xi}$$

m

$$m_{i,kLM}^{(t)} = \sum_{\nu} \sum_{\eta\nu} W_{z,kL,\eta\nu}^{(t)} B_{i,\eta\nu,kLM}^{(t)}$$

h

$$h_{i,kLM}^{(t+1)} = \sum_{\bar{k}} W_{kL,\bar{k}}^{(t)} m_{i,\bar{k}LM}^{(t)} + \sum_{\bar{k}} W_{z,kL,\bar{k}}^{(t)} h_{i,\bar{k}LM}^{(t)}$$

readout

$$E_i = \sum_t R_t(h_i^{(t)}), \quad R_t : h_{i,k00}^{(t)}, \quad E = \sum_i E_i$$

input atomic graph

edge geometry

Interaction Block 1

$$A_i^{(1)} \rightarrow B_i^{(1)} \rightarrow m_i^{(1)} \rightarrow h_i^{(1)}$$

Interaction Block 2

$$A_i^{(2)} \rightarrow B_i^{(2)} \rightarrow m_i^{(2)} \rightarrow h_i^{(2)}$$


invariant readout

$$h_{i,k00}^{(t)} \rightarrow E_i, \quad E = \sum_i E_i$$



MACE: tensor product

Tensor product смешивает l -каналы атомного признака и геометрии ребра в новый l -канал сообщения.




Tensor product смешивает l -каналы и сохраняет эквивариантность сообщения.

Схема построена по Batatia et al, MACE.



MACE: higher-order messages

Tensor product повышает порядок локальных признаков: от парных сообщений к многочастному описанию окружения.




Так MACE компактно кодирует сложное локальное окружение, сохраняя эквивариантность.

Схема построена по Batatia et al., MACE.



MACE: readout энергии и сил

После эквивариантных сообщений MACE считывает атомные вклады энергии, а силы получает как производные полной энергии.




Как и в M3GNet, силы не предсказываются независимо: они получаются через дифференцирование полной энергии.

Схема построена по Batatia et al., MACE.



MACE: fine-tuning и веса функции потерь

В локальных экспериментах MACE дообучается; MACE default, MACE-EW10 и MACE-EW50 — варианты весов функции потерь при fine-tuning, а не разные архитектуры MACE.



	w_E	w_F	роль
MACE default	1	100	базовые веса
MACE-EW10	10	100	вес энергии
MACE-EW50	50	100	сильный вес энергии

MACE-EW50 — вариант fine-tuning с повышенным весом ошибки энергии; это не отдельная архитектура и не базовый MACE.



MatterSim-подход и MACE: архитектурные идеи

Обе модели строят energy-based ML-потенциалы, но закладывают разные способы описания геометрии.

аспект	MatterSim-подход	MACE
представление	граф атомов, связей и состояния	эквивариантный граф локальных окружений
геометрия	расстояния + углы; явная информация о тройках атомов	радиальное кодирование + сферические гармоники
обновление	many-body-to-bond обновляет связи; далее графовая свёртка	tensor product смешивает l -каналы; сообщения более высокого порядка
readout	атомные вклады: $E = \sum_i E_{i,}$ силы из градиента	атомные вклады: $E = \sum_i E_{i,}$ силы из градиента
роль в работе	универсальная модель: предобучение + fine-tuning	универсальная предобученная модель на эквивариантной архитектуре: fine-tuning; варианты весов функции потерь



Перед экспериментами: что именно сравниваем

Дообученные универсальные модели сравниваются с МТР, обученными с нуля.

MatterSim

- универсальная модель
- графовая модель; идеи M3GNet
- fine-tuning на целевых данных

MACE

- универсальная модель
- эквивариантный графовый потенциал
- fine-tuning; варианты весов loss

МТР-16 / МТР-20

- обучение с нуля
- базовый вариант
- уровни 16 и 20

Датасеты

organic: train 300K → test 300K / 600K / 1200K
H₂O: train / validation
MoNbTaVW: train / validation

Метрики


Energy: MAE / RMSE, meV/atom
Forces: MAE / RMSE, meV/Å

Далее переходим к численному сравнению на organic, H₂O и MoNbTaVW.



Экспериментальная схема сравнения

После архитектурного блока сравниваем не архитектуры сами по себе, а качество полученных потенциалов на отложенных выборках.





Далее результаты разбираются по системам: organic → H₂O → MoNbTaVW.



Organic: кривые обучения

organic: обучение на 300K

Кривые обучения используются как sanity check; итоговое сравнение проводится по тестовым метрикам.





Функции потерь различаются между протоколами; кривые обучения служат sanity check, а итоговое сравнение проводится по тестовым метрикам.



Organic: ансамбль MTP на 300K

MTP-16/MTP-20: 5 запусков, train 300K $\rightarrow$ validation 300K

Столбец — mean $\pm$ std по 5 запускам; ромб — одиночный запуск, используемый дальше.



- По MAE одиночный запуск MTP близок к среднему ансамбля на 300K validation.
- Для 600K/1200K далее показана доступная оценка по одному запуску.


mean $\pm$ std показаны только для 300K validation; разброс на 600K/1200K не переносится.




Organic: перенос от 300K к более высоким температурам

train: 300K → test: 300K / 600K / 1200K

Вопрос: сохраняется ли качество при переходе к более высоким температурам?



Energy MAE, meV/atom





Forces MAE, meV/Å

На тестах 300K / 600K / 1200K MACE и MatterSim дают меньшие MAE, чем MTP-16/MTP-20.



Organic: основной вывод



Energy RMSE, meV/atom

**MACE — лучший среди
сравниваемых моделей**

**MatterSim также ниже MTP-
16/MTP-20 по ошибкам**

Forces RMSE, meV/Å



**MTP-20 улучшает MTP-16,
но не закрывает разрыв**

Вывод относится только к organic: обучение на 300K, тесты 300K / 600K / 1200K.



H₂O: кривые обучения

Показаны validation MAE, нормированные на начальное значение.




Кривые обучения служат sanity check оптимизации; итоговое сравнение проводится по validation-метрикам.




H2O: validation results

H2O: train / validation

Energy MAE





Forces MAE



Повышение уровня MTP сильно снижает ошибку, но по силам MTP-20 остаётся хуже MatterSim и MACE.



H2O: RMSE и основной вывод



Energy MAE/RMSE: MatterSim

Forces MAE: MACE



Forces RMSE: MatterSim

Вывод относится к H2O validation split; порядок моделей зависит от метрики.





MoNbTaVW: кривые обучения

MAE-кривые из логов обучения.







MoNbTaVW: основное сравнение по MAE



MTP-20 улучшает MTP-16; MACE-EW50 даёт меньшую MAE, чем MTP-16/MTP-20.





MoNbTaVW: RMSE и эффект уровня MTP



MTP-20 снижает ошибку относительно MTP-16, но MACE-EW50 остаётся ниже MTP-20 по RMSE.



MoNbTaVW: почему нужен MACE-EW50



Выбор MACE-EW50 как основного результата задаётся метриками энергии; ошибки по силам остаются сопоставимыми.

MACE default хуже по ошибке энергии.

Взвешивание ошибки энергии оказалось решающим.

LoRA/freeze/stage2 не заменили MACE-EW50 как основной результат.



MoNbTaVW: основной вывод

МТР-20 улучшает МТР-16

Ошибки ниже по всем validation-метрикам.

MACE-EW50 лучше МТР-16/20

По всем валидационным метрикам:
энергия, силы, MAE и RMSE.

MatterSim лучший по MAE/RMSE энергии

По энергиям MatterSim остаётся
сильнейшей строкой сравнения.

Важен протокол fine-tuning

MACE-EW50 не равен MACE default

Вывод относится к валидационной выборке MoNbTaVW.



Итоговое сравнение

Система

Основное наблюдение

Оговорка / интерпретация

Organic

MACE и MatterSim дают меньшие тестовые ошибки, чем MTP-16/MTP-20

Ансамбль MTP проверен для validation 300K; 600K/1200K показаны как доступная оценка по одному запуску

H₂O

MatterSim лучший по MAE/RMSE энергии и RMSE сил; MACE лучший по MAE сил

Ранжирование зависит от метрики; MTP-20 улучшает MTP-16

MoNbTaVW

MACE-EW50 лучше MTP-16/MTP-20 по validation-метрикам; MatterSim лучший по MAE/RMSE энергии

MACE-EW50 не равен MACE default; важен протокол



Основные выводы

Fine-tuning универсальных моделей работает

MatterSim и MACE дают сильные результаты на отложенных выборках после адаптации.

Протокол fine-tuning важен

Для MoNbTaVW MACE default был слаб по ошибке энергии; MACE-EW50 существенно улучшил результат.

Уровень MTP важен

MTP-20 улучшает MTP-16, но не всегда закрывает разрыв с универсальными моделями.

Выводы зависят от метрики

Лучший метод зависит от системы и метрики: энергия и силы, MAE и RMSE.

Общие выводы ограничены рассмотренными датасетами и validation/test-разбиениями.



Спасибо за внимание

Вопросы

Fine-tuning универсальных ML-потенциалов может быть сильной альтернативой обучению с нуля, но детали протокола критичны.